

Лабораторная 6 - audio

[github classroom task](#)

Порядок сдачи и защиты лабы описан [тут](#)

Дедлайн указан в [таблице с баллами](#)

Данные

Соберите датасет аудиозаписей. Можно спарсить данные с сайта или получить через api. Можно устроить краудсорс датасета вместе с однокурсниками

Идеи задач

Использовать конкретно эти - уже не так интересно. Но для вдохновения подойдет

- классификация вида птицы по ее пению
- классификация жанра песни по ее фрагменту
визуализация эмбедингов может получиться похожей на [everynoise.com](#), а лаба похожей на лабу supervised
- поиск похожих исполнителей
похоже на пункт выше, должно получиться похоже на лабу unsupervised
- классификация языка/пола/возраста говорящих
- классификация своего голоса на аудиодорожке
- детекция голоса на аудиодорожке
по сути, классификация наличия речи в каждой секунде записи
- детекция наличия слова-активации в аудиозаписи. Слушай, Алиса!
- распознавание речи
вариант для очень заинтересованных. lstm + cnn, CTC loss

План действий

1. Соберите датасет аудиозаписей
2. (если нет разметки и она нужна) Разметьте данные
Можете использовать [активное обучение](#), чтобы разметить данные полуавтоматически. Не забывайте проверять качество авторазметки
3. Предобработайте аудио
Можете использовать мел-кепстральное преобразование из librosa, как разобрано на лекции. Или любое другое. В большинстве задач в результате по каждой аудиозаписи получится последовательность мел-кепстральных коэффициентов. Рекомендуется сохранить их, чтобы не проводить преобразование после каждой перезагрузки jupyter-ноутбука
4. Реализуйте и обучите модель
Скорее всего, для решения задачи будет достаточно lstm ячейки. Но можете выбрать CNN или feed-forward нейросеть
Следите, чтобы модель не переобучилась. Логируйте метрики обучения и валидации в tensorboard

5. Создайте эмбединги аудио своего датасета
Используйте эмбединг из последнего слоя вашей модели. Полученные эмбединги отобразите в 2d с помощью tsne/umap. Выделите цветом целевую переменную

Рекомендации

- **не стесняйтесь задавать вопросы в чат курса**
- рекомендуемый размер датасета - более 50 записей на класс в случае классификации. Остальные случаи сложно оценить вне контекста задачи
- используйте `pytorch.nn.Sequential` для слоев модели
- если не получается использовать `torch.device("cuda")` на своей машине, то лучше использовать `google colab`

Для реализации не обязательно, но рекомендуются эти python библиотеки:

- `pytorch`
- `torchaudio`
- `librosa`
- `tensorboard`

Популярные замечания

- используйте конфиг файл для констант
- не коммитить `.idea`
- функции длиннее 20 строк - плохо. Их можно декомпозировать
- не показано, что модель не переобучена. Сравните метрики на `train` и `test`

Теормин

В каждом вопросе про метрики, формулы и тп нужно знать как это рассчитывается и почему формулы именно такие. Зубрить сами формулы не нужно

Преподаватель может задать доп вопрос об использованном вами термине, чтобы понять, что вы понимаете его смысл

1. датасеты LibriSpeech-ASR, LibriVox, CommonVoice: из чего состоят, зачем нужны. Что такое частота дискретизации сигнала? Как влияют на волну изменения ее амплитуды, фазы, частоты?
2. что такое [ряд Фурье](#)? Как работает дискретное преобразование Фурье? Вот неплохие [иллюстрации](#) по преобразованию
3. как выглядит спектрограмма аудиозаписи? Как ее получить? Что такое мел-шкала? Зачем она нужна?
4. как получить мел-кепстральные коэффициенты (mfcc) для аудиозаписи? Можно ли их использовать в качестве эмбедингов?
5. как выглядит мел-спектрограмма аудиозаписи? Чем отличается от обычной спектрограммы такой же аудиозаписи?

6. как использовать RNN-ячейки для обработки спектрограмм? Например, как реализовать классификацию аудио?